



Universidad Peruana de Ciencias Aplicadas (UPC)

Ciclo 2019-2

CC61 - Inteligencia Artificial

TRABAJO 2

Tema:

Aplicación de Red Neuronal para predicción de Cáncer de Mama

PROFESOR DEL CURSO: Willy Ugarte

TRABAJO PRESENTADO POR LOS ALUMNOS:

1. Castillo Arredondo, Geral Esteen
2. Avalos Tapia, Rogger Alonzo

Monterrico, 6 de Noviembre del 2019

ÍNDICE

- 1. Descripción del problema**
- 2. Descripción de la técnica y el algoritmo de inteligencia artificial utilizado**
- 3. Recolección de datos o base de conocimiento.**
- 4. Descripción de las inferencias y modelo matemático.**
- 5. Especificaciones con respecto al desarrollo de la aplicación**
- 6. Pruebas de uso de la aplicación**
- 7. Bibliografía**

1. Descripción del problema

En la actualidad, muchos pueden ser los factores que influyen en la presencia de cáncer de mama. Las mujeres a partir de los 40 años están en la obligación de ir a un centro hospitalario a realizarse análisis para descartar el cáncer de mama (Villarán, 2019). Sin embargo, más del 70% de mujeres dentro de los 40 años a más no se ha hecho un descarte de esta enfermedad. Según Knaul et al. (2009) alrededor de solamente un 10% de las mujeres que se les diagnostica el cáncer de mama lo detectan en la etapa I. Esto quiere decir que la gran problemática está en la detección oportuna de esta enfermedad. Sin duda alguna, las personas que son más propensas a sufrir esta terrible enfermedad, son los hijos o nietos de personas que sufrieron o fallecieron debido al cáncer de seno. Es por ello, es recomendable crear un hábito de descarte de cáncer de mama, recomendando ir al mamógrafo cada año (Villarán, 2019).

Según Sociedad Americana de Oncología Clínica (2019) dentro de un rango de 5 años, la tasa de sobrevivencia de mujeres con cáncer de seno será la siguiente: De cada 100 solo sobreviven 27. Por ello, se destaca la “edad” como un factor importante en la presencia de esta clase de enfermedad maligna. Así también, según la Sociedad Americana del Cáncer [American Cancer Society] (2017), la densidad de las mamas también influye en la fácil detección de cáncer de mama, dificultando su correcto diagnóstico. La incidencia en la presencia del cáncer de seno es variable y depende de muchos factores. Por años se han aplicado distintas técnicas y sistemas que aporten en la detección de cáncer de seno. En este documento haremos mención de algunos de los factores que influyen en la detección de esta enfermedad. Tales como la edad, la densidad del pecho, su margen y los resultados de la evaluación de Breast Imaging Reporting and Data System (BI – RADS). BI RADS, según Halls (2019), es un esquema para los resultados de una mamografía. Esta evaluación en sí clasifica los resultados de la mamografía en 6 categorías.

En este documento, se propondrá una técnica de inteligencia artificial basada en redes neuronales. Dicha técnica o método debe ser capaz de predecir si un tumor de seno es maligno o benigno. La predicción se realizará a partir de datos de entrada relacionados con el tumor a examinar. Un diagnóstico previo de este tipo podría ayudar a los médicos a descartar la posibilidad de cáncer de mama en muchos pacientes. Además, ayudaría a reducir la cantidad de exámenes de detección por paciente.

2. Descripción de la técnica y el algoritmo de inteligencia artificial utilizado

Para resolver, se utilizarán redes neuronales. La red neuronal utilizada para resolver este problema corresponde al Perceptrón Multicapa o “Multilayer Perceptron” (MLP). A continuación, se procederá a describir este tipo de red neuronal:

A. Perceptrón Multicapa

Un red neuronal posee la forma de un conjunto de nodos, los cuales se conectan por medio de aristas unidireccionales con pesos. Para poder definir adecuadamente un Perceptrón Multicapa, es factible dar la siguiente información:

Un perceptrón multicapa es una red neuronal que conecta varias capas en un grafo dirigido, lo que significa que la ruta de la señal a través de los nodos solo va en una dirección. Cada nodo, aparte de los nodos de entrada, tiene una función de activación no lineal. Un MLP utiliza la propagación hacia atrás como una técnica de aprendizaje supervisado. Como existen múltiples capas de neuronas, MLP es una técnica de aprendizaje profundo. (El Perceptrón Multicapa, s.f)

MLP está basada en otra red más simple conocida como perceptrón simple solo que la cantidad de capas ocultas puede ser mayor a uno. De acuerdo a lo mencionado por la Escuela Superior de Cómputo [ESCOM] (2009), el Perceptrón básico de dos capas solo posee la capacidad de determinar dos regiones separadas por un límite lineal, el cual se encuentra en el espacio de patrones de entrada. Por otro lado, un Perceptrón Multicapa permite resolver problemas que no sean linealmente separables. Ahora bien, se procederá a explicar el proceso de entrenamiento de la red neuronal. El algoritmo inicia con la inicialización aleatoria de todos los pesos. Luego de esto, se procede con 2 fases importantes, las cuales son Propagación y Aprendizaje. Dichas fases se detallaran a continuación:

Propagación

Cabe mencionar que, en este paso, se lleva a cabo el cálculo del resultado de salida de la red desde los datos de entrada hacia delante (Calvo, 2018). La fórmula matemática utilizada para la propagación se basa en lo siguiente:

$$y = f_i(w_{1i} y_1 + w_{2i} y_2 + w_{3i} y_3 + \dots + w_{ji} y_j)$$

La fórmula dada anteriormente se aplica para cualquier nodo de la red neuronal MLP. La variable i es el número asignado al nodo actual. Los parámetros y_1 , y_2 y y_3 hasta y_j corresponden a los valores de salida de los nodos de la capa anterior, los cuales están conectados al nodo actual. Si el nodo actual se encuentra en la primera capa, entonces y_1 , y_2 y y_3 hasta y_j son los datos de entrada de la red. Los valores w corresponden a los pesos de las conexiones entre los nodos de la capa anterior o datos de entrada y el nodo actual. f_i representa la función de activación respectiva. Asimismo, y representa el valor de salida calculado en el nodo actual. Si el nodo no está en la última capa, dicho valor será utilizado para el cálculo de los valores de salida de los nodos conectados en la capa posterior. De lo contrario, el valor mencionado corresponde al valor de salida de la red neuronal.

Aprendizaje:

Continuando con el asunto, el siguiente paso del algoritmo consiste en la parte de aprendizaje. Calvo (2018) argumenta lo siguiente con respecto a esta etapa:

Los errores obtenidos a la salida del perceptrón se van propagando hacia atrás (backpropagation) con el objetivo de modificar los pesos de las conexiones para que el valor estimado de la red se asemeja cada vez más al real, esta aproximación se realiza mediante la función gradiente del error.

La propagación hacia atrás usa el siguiente modelo matemático para la optimización de pesos respectiva:

$$w = w' + \alpha \delta x$$

La fórmula especificada anteriormente se calcula para todos los pesos de la red neuronal MLP. El parámetro w' corresponde al valor actual del peso de la arista respectiva. El factor α representa la tasa de aprendizaje, la cual varía entre 0 y 1. Igualmente, el parámetro x es el valor de salida del nodo, del cual sale la arista unidireccional correspondiente al peso a optimizar. Por último, δ corresponde al error calculado y propagado por toda la red neuronal. El error inicial se calcula con respecto al valor de salida de la red siguiendo el siguiente modelo matemático:

$$\delta = (s - y) y (1 - y)$$

En el modelo presentado anteriormente, el parámetro y representa el valor de salida obtenido por la red neuronal. Además, el factor s corresponde al valor de salida esperado o deseado. Este error es recalculado para cada nodo y propagado con el objetivo de optimizar todos los pesos respectivos.

Durante el proceso de entrenamiento, las 2 fases detalladas anteriormente son ejecutadas para todos los datos de entrenamiento. El procedimiento especificado se repite hasta convergencia o finalización. Al finalizar esta etapa, la red se encuentra entrenada y lista para ser testada. Para el proceso de testeo, se seleccionan datos de prueba y se realiza la propagación hacia adelante con dichos datos. La propagación da como resultado la predicción de la red neuronal MLP. Dicho resultado puede ser comparado con el valor real o deseado con el propósito de determinar la precisión de la red.

B. Aplicación de la Técnica en el problema

De acuerdo a nuestro problema, se desea diagnosticar si un tumor representa o no cáncer de mama a partir de datos respectivos dados. Un MLP es ideal para resolver este problema, debido a la optimización de pesos de la red producto del entrenamiento. Luego de dicho entrenamiento, es factible la predicción de un dato de salida a partir de datos de entrada. Bajo el contexto del problema, los datos de entrada son los datos por cada paciente y el dato de salida corresponde al diagnóstico del tumor. Se utilizará el 80% de la base de conocimiento para poder entrenar (FIT) la red neuronal con el fin de entrenar una sección de base de conocimiento. De esta manera, con ello poder interpretar el resto de datos y designarlos en grupos previamente definidos en el código. En este caso, para definir los X (datos de entrada) de nuestra función de red neuronal están los datos de BI RADS, AGE, SHAPE, MARGIN y DENSITY. Por otro lado para definir las Y (dato de salida) se tiene en cuenta el campo SEVERITY. Los atributos mencionados anteriormente son los correspondientes al conjunto de datos utilizado para resolver el problema planteado.

3. Recolección de datos o base de conocimiento.

Se obtuvo el conjunto de datos de una página web dedicada a la publicación de conjuntos de datos de múltiples temas y/o ámbitos. Dicha página web es conocida como ML Data. El conjunto de datos es sobre pacientes, los cuales han sido sometidos previamente a una mamografía. Los resultados de dicha mamografía son descritos por un sistema estándar conocido como BI-RADS. BI-RADS categoriza los resultados en clases numeradas de 0 a 6, donde la categoría 6 es sinónimo de cáncer de seno detectado y la categoría 0 representa que es necesario realizar más exámenes (Sociedad Americana del Cáncer, 2019). Para diagnosticar si un tumor de seno es benigno o maligno se requieren múltiples exámenes. El objetivo con estos datos es, a partir de un primer examen de detección de cáncer de mama, diagnosticar si efectivamente la persona posee un tumor maligno o no. Si se logra realizar efectivamente, esto ahorraría muchos costes con respecto a futuros exámenes y ayudaría a los médicos a descartar rápidamente. A continuación, se procederá a presentar la descripción del conjunto de datos:

A. Descripción del conjunto de datos

La mamografía es el mejor método para el diagnóstico del cáncer de seno disponible en la actualidad. No obstante, el pequeño valor predictivo positivo de la biopsia de mama como resultado de la interpretación de la mamografía produce que un 70% de las biopsias sean innecesarias. Esto último, ya que el resultado para dichos casos corresponde a un tumor benigno.

El conjunto de datos va a ser utilizado para predecir la gravedad (benigna o maligna) de una lesión de masa mamográfica a partir de los atributos de BI-RADS y la edad de la paciente. Se

cuentan con 516 masas benignas y 445 malignas, las cuales han sido identificadas con mamografías digitales de campo completo recopiladas en el Instituto de Radiología de Universidad Erlangen-Nuremberg entre 2003 y 2006.

B. Detalle de los atributos

Llegados a este punto, se procederá a describir el significado de los atributos o variables de cada dato contenido por el conjunto de datos:

- Evaluación BI-RADS o BI RADS assessment: Cada instancia cuenta con una evaluación BI-RADS, la cual varía de 1 (definitivamente benigna) a 5 (altamente sugestiva de malignidad) asignada en un proceso de revisión por los médicos. Este atributo es de tipo nominal.
- Edad o Age: es la edad de la persona. Este atributo es de tipo numérico.
- Forma o Shape: Es la forma en si del seno de una mujer. Está categorizado de la siguiente manera: Redonda = 1, Ovalado = 2, Lobular = 3, Irregular = 4. Este atributo es de tipo nominal.
- Margen o Margin: Es el margen que forma el seno como sombra en perfil. Está categorizado de la siguiente manera: Circunscrito = 1, Microlobulado = 2, Oscurecido = 3, Mal definido = 4, Espiculado = 5. Este atributo es de tipo nominal.
- Densidad o Density: Un coeficiente de densidad del seno. Está categorizado de la siguiente manera: Alto = 1, Iso = 2, Bajo = 3, Contiene grasa = 4. Este atributo es de tipo ordinal.
- Severidad: Es 1 si el tumor es maligno y 0 si el tumor no es maligno. Este atributo es de tipo nominal.

En total el conjunto de datos contiene 961 instancias con las que se trabajara en el sistema experto de inteligencia artificial. Los datos se componen de 6 atributos y se cuentan con valores perdidos. Los datos fueron publicados en 2007.

C. Fuente de datos

Los datos fueron obtenidos de una página web llamada MLData. El link correspondiente a la fuente de datos directa es el siguiente:

https://www.mldata.io/dataset-details/mammogram/#customize_download

La licencia corresponde a UCI Machine Learning, la cual cuenta con muchos conjuntos de datos para ser aplicados en aprendizaje de máquina. En la siguiente imagen, se puede apreciar el sitio web de donde salieron los datos:

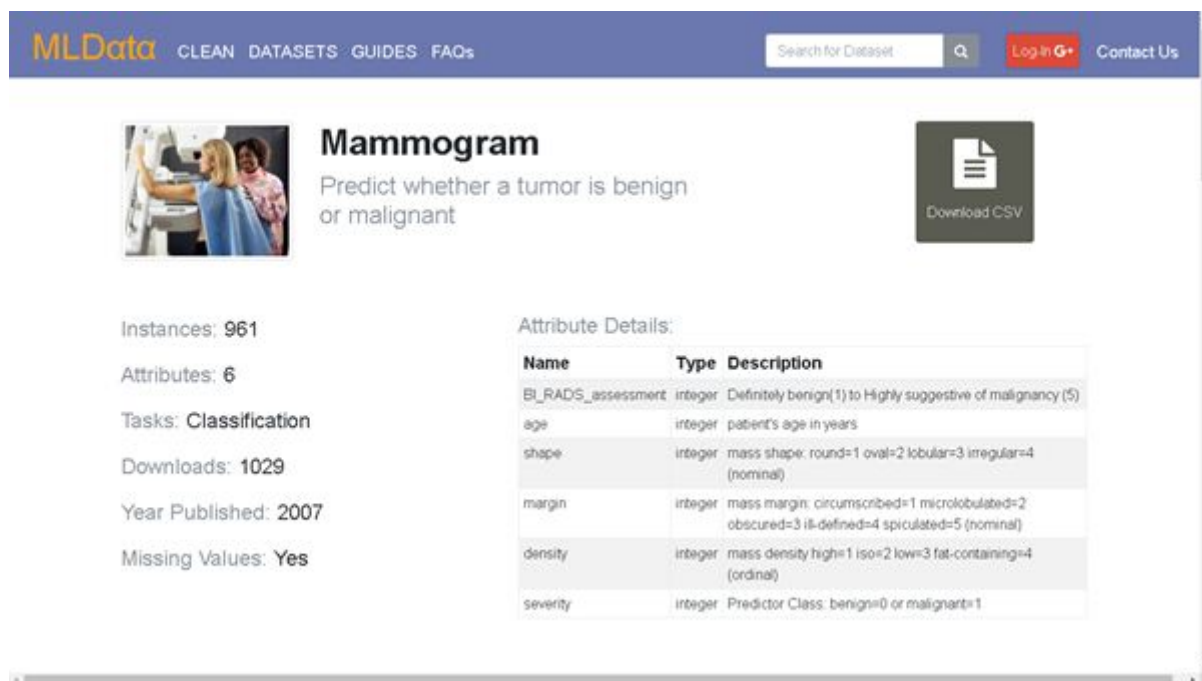


Figura 1. Fuente de datos. Elaboración propia.

4. Descripción de las capas, función de activación y modelo matemático.

En esta parte se pasará a describir la estructura de la red neuronal multilayer perceptron (MLP) que permite resolver el problema planteado. A continuación, se describen los aspectos que engloban esta parte.

A. Determinación del Número óptimo de neuronas y capas

Para definir la cantidad óptima de capas y nodos por capa se utilizó la siguiente metodología:

En lo que respecta al número de capas y neuronas por capa, no existe un método o regla que determine el número óptimo de neuronas ocultas para resolver un problema dado, generalmente se determinan por prueba y error, es decir partiendo de una arquitectura ya entrenada, se realizan cambios aumentando y disminuyendo el número de neuronas ocultas y el número de capas hasta conseguir la arquitectura que se ajuste a la solución del problema. (Villada, Muñoz y García-Quintero, 2016, p.146)

Ahora bien, de acuerdo a la metodología explicada anteriormente, se debe definir una solución del problema alcanzable. En otras palabras, se debe definir un porcentaje de precisión, el cual debe ser alcanzado por la red neuronal, para considerar que se ha solucionado el problema. Luego de que se define dicho porcentaje, se debe aplicar prueba y error con el objetivo de determinar el número óptimo de neuronas. En este problema, la precisión es un factor muy importante, ya que se trata de el diagnostico de una enfermedad cancerígena. En los parámetros de evaluación de la red, se maneja un porcentaje de precisión

para diagnosticar tumores benignos y otro para malignos respectivamente. Si un tumor maligno es diagnosticado como benigno, entonces se llega a un estado crítico. Esto último es así, porque la persona diagnosticada corre riesgo de morir sino se le da el tratamiento adecuado. Por esta razón, se considera que la precisión de la red para diagnosticar un tumor maligno es la más crítica e importante. Por ello, se establece que la precisión para predecir tumores malignos debe ser mayor a 90% y para benignos, mayor igual a 75%. Los porcentajes de precisión especificados anteriormente fueron superados con la siguiente arquitectura en la red neuronal:

- **Cantidad de capas:** 3 capas
- **Porcentaje de datos de entrenamiento:** 80%
- **Número de nodos en cada capa:** En la primera capa, nos encontramos 200 neuronas. En la segunda, hay 150 neuronas. Por último, en la tercera capa, hay 100 nodos.
- **Método para la Función de activación:** Función de la Tangente Hiperbólica.
- **Método para la optimización de pesos:** Optimizador Estocástico basado en la Gradiente.
- **Número máximo de iteraciones:** 500 iteraciones

Se logró alcanzar un 90% de precisión para el diagnóstico de tumores malignos y un 77% de precisión en el caso de los tumores benignos. Esto último significa que por cada 10 personas padecientes de tumores malignos, 9 serán diagnosticadas correctamente.

B. Descripción de cada capa

De acuerdo a lo mencionado por Calvo (2018), la arquitectura de un Perceptrón Multicapa se divide en tres partes: capa de entrada, capas ocultas y capa de salida. Es factible la visualización de lo descrito a continuación:




Figura 2. Arquitectura de un Perceptron Multicapa. Recuperado de <http://www.diegocalvo.es/wp-content/uploads/2017/07/perceptron-multicapa.png>

Como se puede ver en la imagen (Figura 2), la capa de entrada se encarga de conectar la red con la parte externa, cada neurona se corresponde con cada uno de los valores de entrada (Calvo, 2018). Así también, “las capas ocultas son una aglomeración de capas en las que cada activación de una salida procede de la suma ponderada de las activaciones de la capa anterior conectadas, más sus correspondientes umbrales” (Calvo, 2018). Por último, la capa de salida enlaza las capas ocultas con el valor de salida de la red correspondiente al resultado.

Ahora bien, se procederá a establecer el significado de cada una de las capas de la red neuronal propuesta. Dado que el MLP planteado sólo posee 3 capas, como se determinó en el ítem anterior, solo se contará con una capa oculta. Si se considera la estructura dada anteriormente, la primera capa de nuestra red corresponde a la capa de entrada. En ese sentido, la segunda capa se relaciona directamente con la capa oculta. En otras palabras, en la segunda capa, se realiza todo el proceso de propagación y aprendizaje profundo característico de un Perceptron Multicapa. Igualmente, la tercera y última capa cumple con la función de capa de salida, es decir, se relaciona directamente con el resultado de la red.

C. Relación entre capas

En esta parte, se explicará la relación entre las tres capas que componen la red neuronal que resuelve el problema planteado. Dicha relación será descrita de forma matemática y algorítmica. La primera capa recibe los datos de entrada de la red y los conecta con la capa oculta. Con respecto a la propagación, cada neurona de la primera capa procesa el siguiente cálculo matemático:

$$y = f(w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4 + w_5 x_5)$$

Los valores x corresponden a los valores de entrada de la red. Los parámetros w son los pesos de las conexiones respectivas a cada dato de entrada. f representa la función de activación y el parámetro y , el valor de salida del nodo. Las instancias son obtenidas del conjunto de datos correspondiente al problema. Son cinco atributos por cada instancia. Por este motivo, son cinco valores x y w en el modelo matemático. En ese sentido, durante la propagación hacia adelante, la relación entre la primera capa y la capa oculta se basa en el parámetro y . Esto es así, porque y ingresa como valor de entrada para los nodos de la segunda capa. El siguiente modelo matemático corresponde a lo que procesa cada nodo de la capa oculta a lo largo de la propagación:

$$Y = f(w_1 y_1 + w_2 y_2 + w_3 y_3 + w_4 y_4 + w_5 x_5 + \dots + w_j y_j)$$

Los valores de y son aquellos valores de salida de los nodos de la primera capa. Dichos valores son procesados por cada neurona de la segunda capa o capa oculta. Producto de ello se obtiene el dato de salida de cada nodo de la capa intermedia. Dicho dato está representado por la variable Y . La relación matemática, durante la propagación, entre la primera y segunda capa se basa en lo descrito anteriormente. De igual forma, dicha relación matemática se cumple de manera análoga para la segunda y tercera capa respectivamente. Una vez que se han calculado los datos de salida para todas las neuronas de la capa de salida, se calcula el resultado de la red neuronal aplicando el último modelo matemático especificado. Es importante considerar que para este último cálculo, los parámetros y corresponden a los valores de salida de la tercera capa. Ahora bien, se procederá a explicar la relación entre capas durante el proceso de aprendizaje o propagación hacia atrás. Se calcula el error para cada nodo. Luego de ello, se recalculan u optimizan los pesos de cada arista que apunte a dicho nodo. Es importante resaltar que las conexiones entre nodos están estructuradas como aristas unidireccionales. Luego de ello, el error es calculado para los nodos de la capa anterior teniendo en cuenta los valores de entrada de los nodos de la capa posterior. En ese sentido, la relación entre las capas a lo largo del aprendizaje está basado en la propagación del error hacia atrás. Esto último es clave, ya que permite la optimización de la red neuronal durante el entrenamiento.

D. Descripción de la función de activación

Para determinar la función de activación ideal para nuestro problema, se llevó a cabo una comparación de los resultados obtenidos utilizando diferentes métodos. Entre los métodos comparados es factible mencionar los siguientes: Función de identidad, función sigmoidea logística, función de la tangente hiperbólica y la función de unidad lineal rectificadora. La función de activación utilizada en la red neuronal implementada corresponde a la tangente hiperbólica. Se utilizó esta función, ya que es la que mejor se adaptó a los datos dados. Asimismo, se obtuvieron los mejores resultados con la función de activación especificada.

Llegados a este punto, de acuerdo a la Escuela Técnica Superior de Náutica y Máquinas Navales (s.f), el modelo matemático respectivo a la tangente hiperbólica es el siguiente:

$$\tanh(x) = (e^x - e^{-x}) / (e^x + e^{-x})$$

El parámetro x corresponde al valor de salida de un nodo antes de pasar por la función de activación. Luego de pasar por dicha función, los valores son transformados de tal manera que son manejables para el algoritmo.

5. Especificaciones con respecto al desarrollo de la aplicación

Lenguaje de programación utilizado: Python en la versión 3.7

Librerías de Python utilizadas: Numpy, Pandas, os.path, Tkinter, Sklearn

Sobre ejecución del programa: Para la ejecución del programa, se está utilizando IDLE, el cual es un entorno de desarrollo integrado para Python. Se debe de abrir el archivo correspondiente al código fuente haciendo uso de la aplicación IDLE. Luego de ello, ejecutar el código y acceder a la interfaz del programa.

6. Pruebas de uso de la aplicación

A continuación, se muestran capturas de pantalla de los distintos aspectos y características del programa realizado. Cada captura está correctamente descrita.

- A. Interfaz inicial:** Es la parte inicial de la aplicación. Al inicio, todos los campos de texto y datos se muestran en blanco o en cero. Los campos de selección se encuentran con su valor predeterminado. En la parte superior de la pantalla, se encuentran todos los datos que deben ser ingresados por el usuario. Por otro lado, en la parte inferior, debajo del botón “Entrenar y Probar”, se muestran todos los datos de salida del programa, es decir, la visualización de resultados. Lo descrita anteriormente se muestra a continuación:

Red Neuronal para predecir Cáncer de seno

Selecciona el archivo con los datos

Seleccionar archivo

Ingrese el porcentaje de datos de entrenamiento (%):

Ingrese el numero de nodos por capa ordenadamente separados por comas:

Ingrese el numero maximo de iteraciones:

Función de activación: Optimización de pesos:

Entrenar y Probar

Porcentaje de precisión para diagnosticar un tumor benigno (%):

Porcentaje de precisión para diagnosticar un tumor maligno (%):

Cantidad de tumores benignos diagnosticados correctamente:

Cantidad de tumores benignos diagnosticados como malignos:

Cantidad de tumores malignos diagnosticados correctamente:

Cantidad de tumores malignos diagnosticados como benignos:

B. Ingreso de datos: En esta parte, se procederá a describir el ingreso de datos en la interfaz gráfica del programa. El programa tiene como objetivo recibir los datos necesarios para el entrenamiento y prueba de un MLP (Multi Layer Perceptron). Esto último con el objetivo de diagnosticar cáncer de mama por medio de una red neuronal. En el primer input, se debe seleccionar un archivo de tipo csv con los datos correspondientes a ser utilizados. En el segundo input, se debe especificar el porcentaje de datos de entrenamiento. En el tercer input, se debe ingresar el número de nodos por capa en el siguiente formato: X, Y, Z, donde X, Y y Z son números enteros. En el cuarto input, se debe ingresar el número máximo de iteraciones. Por debajo, se encuentran dos cajas de selección. Una de ellas para indicar la función de activación y la otra para indicar el método de optimización de pesos. Por último, hacer click en el botón de “Entrenar y Probar” para obtener los resultados. A continuación, se ejemplifica lo descrito:

Red Neuronal para predecir Cáncer de seno

Selecciona el archivo con los datos

C:/Users/COMPUTER/Desktop/U_esteen/Trabajo 2 IA/mamdataset.csv

Seleccionar archivo

Ingrese el porcentaje de datos de entrenamiento (%): 80

Ingrese el numero de nodos por capa ordenadamente separados por comas:

200, 100, 50

Ingrese el numero maximo de iteraciones: 800

Función de activación: Optimización de pesos:

relu adam

Entrenar y Probar

Porcentaje de precisión para diagnosticar un tumor benigno (%): 0

Porcentaje de precisión para diagnosticar un tumor maligno (%): 0

Cantidad de tumores benignos diagnosticados correctamente: 0

Cantidad de tumores benignos diagnosticados como malignos: 0

Cantidad de tumores malignos diagnosticados correctamente: 0

Cantidad de tumores malignos diagnosticados como benignos: 0

C. Visualización de resultados: En esta última parte, se procederá a explicar cómo se lleva a cabo la visualización de resultados en la interfaz gráfica desarrollada. Una vez presionado el botón de “Entrenar y Probar”, el algoritmo procede a ejecutarse, es decir, la red neuronal es entrenada y testeada. Luego de ello, los resultados obtenidos son mostrados en pantalla. En el primer output, se muestra el porcentaje de precisión para diagnosticar un tumor benigno, es decir, el porcentaje de tumores benignos diagnosticados adecuadamente. En el segundo output, se muestra el porcentaje de precisión para diagnosticar un tumor maligno, en otras palabras, el valor porcentual de tumores malignos diagnosticados correctamente. En el tercer output, se muestra la cantidad de tumores benignos que fueron diagnosticados como tumores benignos. En el cuarto output, se debe observar el número de tumores benignos que fueron diagnosticados erróneamente como malignos. Ahora bien, en el quinto output, se

especifica el número de tumores malignos que fueron diagnosticados asertivamente como malignos. Por último, en el sexto output, se visualiza la cantidad de tumores malignos diagnosticados erróneamente como benignos. Los cuatro últimos outputs descritos son obtenidos de los datos dados por la matriz de confusión. En ese sentido, se procederá a mostrar una captura correspondiente a lo descrito:

Red Neuronal para predecir Cáncer de seno

Selecciona el archivo con los datos

C:/Users/COMPUTER/Desktop/U_esteen/Trabajo 2 IA/mamdataset.csv

Seleccionar archivo

Ingrese el porcentaje de datos de entrenamiento (%): 80

Ingrese el numero de nodos por capa ordenadamente separados por comas: 500,300,200

Ingrese el numero maximo de iteraciones: 1000

Función de activación: relu

Optimización de pesos: adam

Entrenar y Probar

Porcentaje de precisión para diagnosticar un tumor benigno (%):	73.40425531
Porcentaje de precisión para diagnosticar un tumor maligno (%):	90.41095890
Cantidad de tumores benignos diagnosticados correctamente:	69
Cantidad de tumores benignos diagnosticados como malignos:	25
Cantidad de tumores malignos diagnosticados correctamente:	66
Cantidad de tumores malignos diagnosticados como benignos:	7

7. **Bibliografía**

- Calvo, D. (2018, 8 diciembre). Perceptrón Multicapa – Red Neuronal. Recuperado 5 noviembre, 2019, de <http://www.diegocalvo.es/perceptron-multicapa/>
- Elter, M., Schulz-Wendtland, R., & Wittenberg, T. (2007). Mamograma: Predecir si un tumor es benigno o maligno . Recuperado 5 noviembre, 2019, de <https://www.mldata.io/dataset-details/mammogram/>
- El Perceptrón Multicapa (MLP). (s.f.). Recuperado 5 noviembre, 2019, de https://www.ibiblio.org/pub/linux/docs/LuCaS/Presentaciones/200304curso-glisa/redes_neuronales/curso-glisa-redes_neuronales-html/x105.html
- ESCOM. (2009, 22 septiembre). El Perceptrón Multicapa. Recuperado 5 noviembre, 2019, de <https://es.slideshare.net/mentelibre/el-perceptrn-multicapa>
- Escuela Técnica Superior de Náutica y Máquinas Navale. (s.f.). Funciones hiperbólicas. Recuperado 6 noviembre, 2019, de http://www.ehu.es/juancarlos.gorostizaga/apoyo/func_hiperbolic.htm
- Halls, D. (2019, 7 mayo). Cáncer de Mama. Recuperado 5 noviembre, 2019, de <https://breast-cancer.ca/bi-rads/>
- Knaul, F. M., Nigenda, G., Lozano, R., Arreola-Ornelas, H., Langer, A., & Frenk, J. (2009). Cáncer de mama en México: una prioridad apremiante. Recuperado 5 noviembre, 2019, de https://www.scielo.org/scielo.php?pid=S0036-36342009000800026&script=sci_abstract
- Sociedad Americana de Oncología Clínica. (2019, 24 abril). Cáncer de mama: Estadísticas. Recuperado 6 noviembre, 2019, de <https://www.cancer.net/es/tipos-de-c%C3%A1ncer/c%C3%A1ncer-de-mama/estad%C3%ADsticas>
- Sociedad Americana del Cáncer. (2019, 3 octubre). Cómo entender su informe de mamograma. Recuperado 5 noviembre, 2019, de <https://www.cancer.org/es/cancer/cancer-de-seno/pruebas-de-deteccion-y-deteccion-temprana-del-cancer-de-seno/mamogramas/como-entender-su-informe-de-mamograma.html>
- Sociedad Americana del Cáncer. (2017, 9 octubre). Densidad de los senos e informe de su mamograma. Recuperado 4 noviembre, 2019, de

<https://www.cancer.org/es/cancer/cancer-de-seno/pruebas-de-deteccion-y-deteccion-temprana-del-cancer-de-seno/mamogramas/la-densidad-de-los-senos-y-el-informe-de-su-mamograma.html>

- Villada, F., Muñoz, N., & García-Quintero, E. (2016). Redes Neuronales Artificiales aplicadas a la Predicción del Precio del Oro. *Información tecnológica*, 27(5), 143–150. <https://doi.org/10.4067/s0718-07642016000500016>
- Villarán, M. (2019, 1 octubre). ¿En qué consiste la mamografía y cada cuánto realizársela?. Recuperado 5 noviembre, 2019, de <https://blog.oncosalud.pe/en-que-consiste-la-mamografia-y-cada-cuanto-realizarsela>